ИИ ЧЕМП
КЕЙС Т БАНК

mango_united, СПб

Щеглов Михаил, Марков Марк &
Сычев Николай

ТЕКУЩИЙ РЕЗУЛЬТАТ

В общем зачете наша модель заняла 3 место

#	△	Team	Members	Score	Entries	Last	Solution
1	▲ 3	14-Bit MISIS_Мск		0.97590	37	27m	
2	▲ 3	R^2 negative_Мск		0.96967	28	2h	
3	▲ 6	mango_united_СПб		0.96400	13	3h	

НАША МОДЕЛЬ

Модель на базе CatBoost с использованием фиксированных текстовых эмбеддингов & гибридных признаков

АРХИТЕКТУРА РЕШЕНИЯ

Feature Engineering слой

- Нормализация текста и извлечение доменных атрибутов комнаты.
- Формирование hotel-aware признаков (сравнение с профилем отеля).

Text Encoder слой

- KFold-обучение трансформера для снижения рисков учетки и завышения метрик (OOF).
- Генерация трансформерных мета-признаков на train/test.

Embedding слой

- Извлечение плотных эмбеддингов тем же encoder.
- PCA-сжатие и добавление компонент в табличные фичи.

Final Ranker/Classifier слой

- Обучение CatBoost на гибридном наборе фич.
- Валидация по PR-AUC, подбор порога, переобучение production-модели на полном train.

FEATURE ENGINEERING: ДОМЕННЫЕ ПРИЗНАКИ

Структурные признаки

- Длина текста, количество слов и токенов, соотношение уникальных слов.
- Standard/Deluxe, вместимость, наличие балкона, ванной комнаты, спальных мест и типа вида.
- Сравнение текущей комнаты с профилем отеля и расчет доли комнат с ключевыми атрибутами (например, балконом).

Эмбеддинги

- Текст прогоняется через трансформер
- Берется последний скрытый слой
- По токенам делается mean pooling
- Вектор нормализуется
- Далее PCA в 64 размерность

МЕТА-ПРИЗНАКИ ДЛЯ ТРАНСФОРМЕРА

01 trf_proba:

Это вероятность класса 1 от трансформера. По сути: «насколько трансформер считает, что данных мало».

02 trf_logit:

Это сырой сигнал до вероятности: в коде считается как logit_class1 - logit_class0. То есть насколько класс 1 сильнее класса 0.

03 trf_margin

Это abs(proba - 0.5). Насколько трансформер уверен. Если около 0 он сомневается. Если далеко от 0.5 уверен.

04 trf_entropy

Это энтропия бинарной вероятности. Она тоже измеряет неопределённость, только чуть по-другому: максимум около 0.5, минимум около 0 и 1.

FEATURE IMPORTANCE: CatBoost & transformer

- hotel_id (11.44) — Самый сильный признак: модель запоминает паттерны конкретных отелей.
- trf_proba (5.52) — Вероятность класса 1 от трансформера; самый сильный текстовый семантический сигнал.
- trf_margin (4.09) — Насколько уверенно трансформер отклонился от 0.5; мера уверенности модели.
- trf_logit (3.79) — Сырая сила сигнала трансформера до вероятности; полезно для CatBoost как более линейный сигнал.
- hotel_share_balcony (3.59) — Доля комнат с балконом внутри отеля; hotel-aware контекст.
- trf_entropy (2.76) — Неопределённость трансформера: чем выше, тем описание двусмысленнее или беднее.
- rel_business_attr_vs_hotel (2.56) — Насколько текущая комната богаче или беднее по атрибутам, чем средняя комната этого же отеля.
- room_level (2.54) — Уровень номера: standard / deluxe / suite / premium и т.д.
- view_type (1.64) — Тип вида: sea / city / garden / panoramic и т.п.
- core_room_level (1.42) — Уровень номера после очистки хвостов и скобок, то есть более чистая версия room_level.

Модель в основном опирается на три группы факторов: семантика текста, полнота бизнес-атрибутов комнаты и локальный контекст конкретного отеля.

ГИПЕРПАРАМЕТРЫ

- **Функция потерь:** Logloss с оптимизацией по метрике PRAUC.
- **Итерации:** До 2000 шагов (с ранней остановкой по 100 раундам).

- **Гиперпараметры:** Depth = 14 (высокая глубина для захвата сложных паттернов), Learning rate = 0.05.
- **Регуляризация:** L2-leaf-reg = 3, Random-strength = 0.1 для борьбы с переобучением.

- **Балансировка: Автоматическая** настройка весов классов для учета дисбаланса данных.
- **Сэмплирование:** Bernoulli-bootstrap с subsample 0.8 для повышения обобщающей способности модели.

АНАЛИЗ PR-AUC

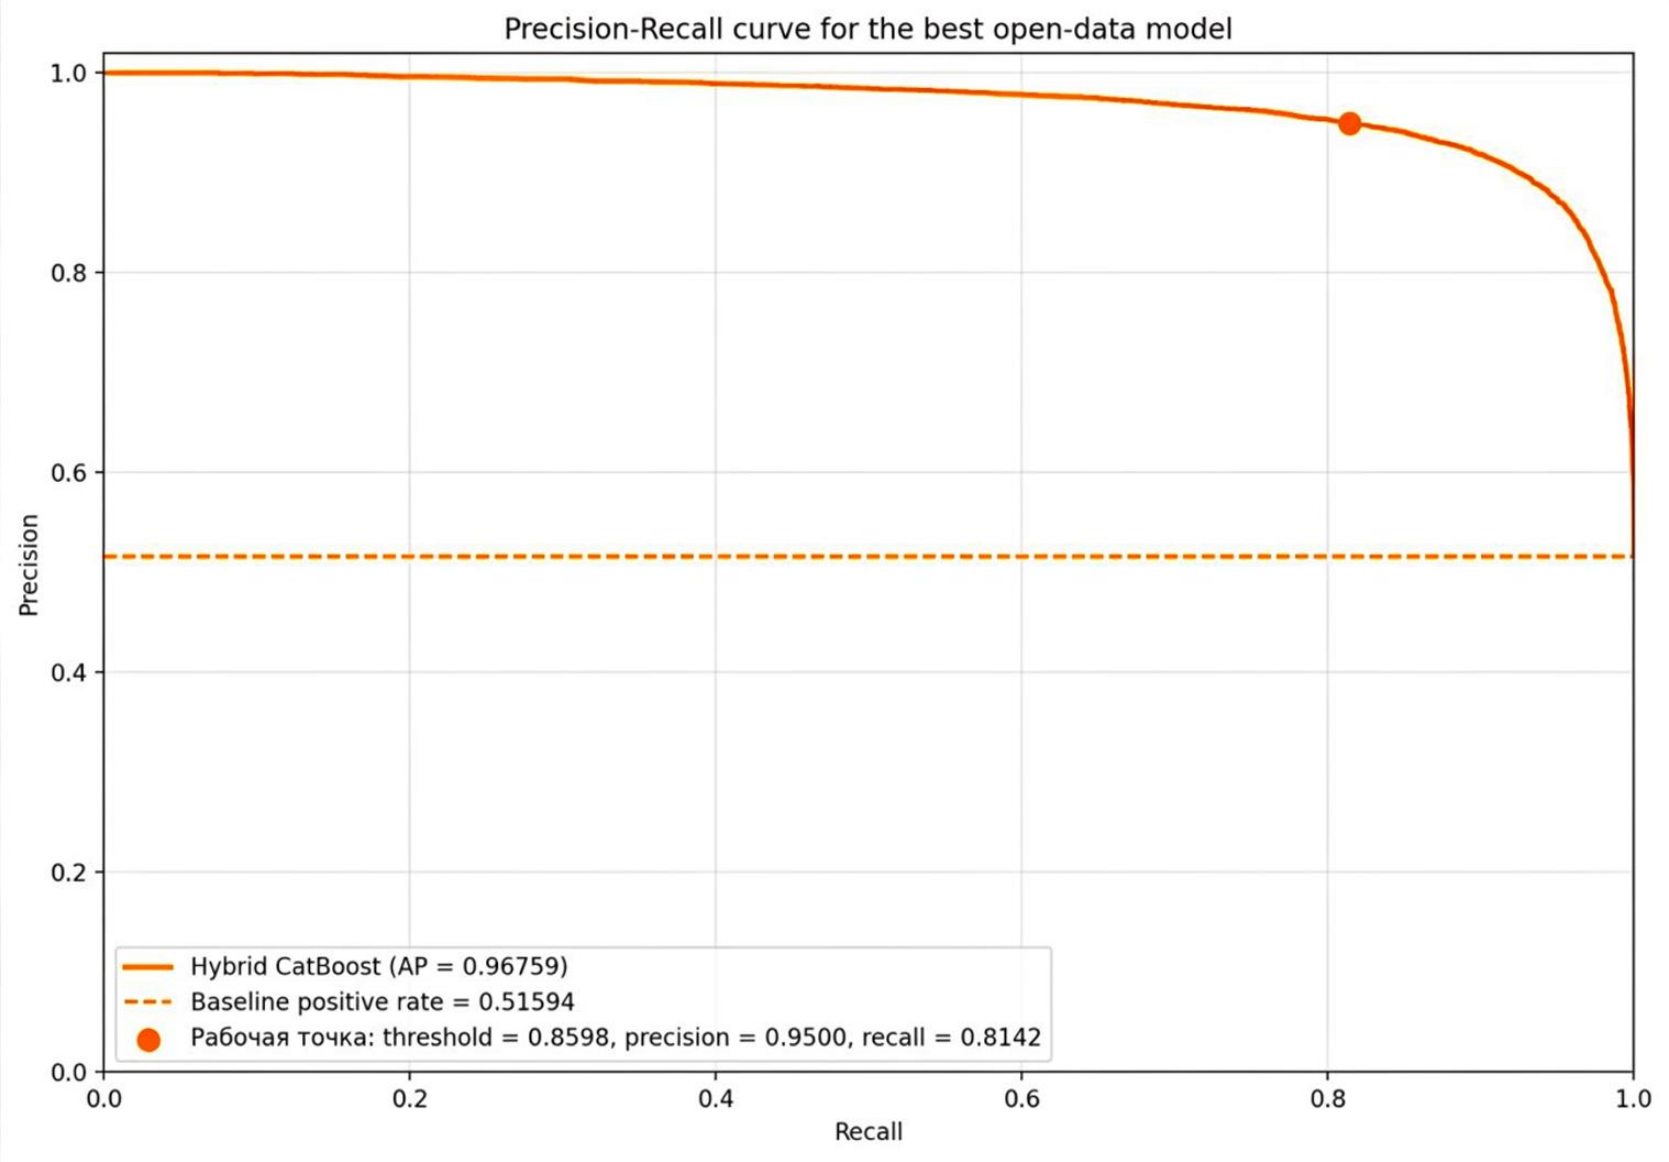

Модель обеспечивает высокую точность (AP ~0.968), позволяя эффективно выявлять недостаточно информативные описания комнат.

Алгоритм автоматически фильтрует более 81% проблемных кейсов до передачи в краудсорсинг.

АНАЛИЗ PR-AUC

Для anti-hotel модели без hotel_id и hotel-aware признаков качество на случайных разбиениях: средний PR-AUC на random CV составил около 0.916.

Модель сохраняет полезный сигнал даже без прямой привязки к конкретным отелям. При более жёсткой проверке на grouped CV по hotel_id качество снижается до PR-AUC ≈ 0.870, что говорит о наличии скрытой внутреотельной специфики в самих названиях комнат.

При настройке на высокую точность модель становится очень консервативной: она требует высокий порог и поэтому ловит только ограниченную долю проблемных комнат.

Эта модель более устойчива к зависимости от hotel_id, но заметно уступает полной hybrid-модели по чувствительности и поэтому лучше подходит как страховочная submission-модель, а не как основной вариант.

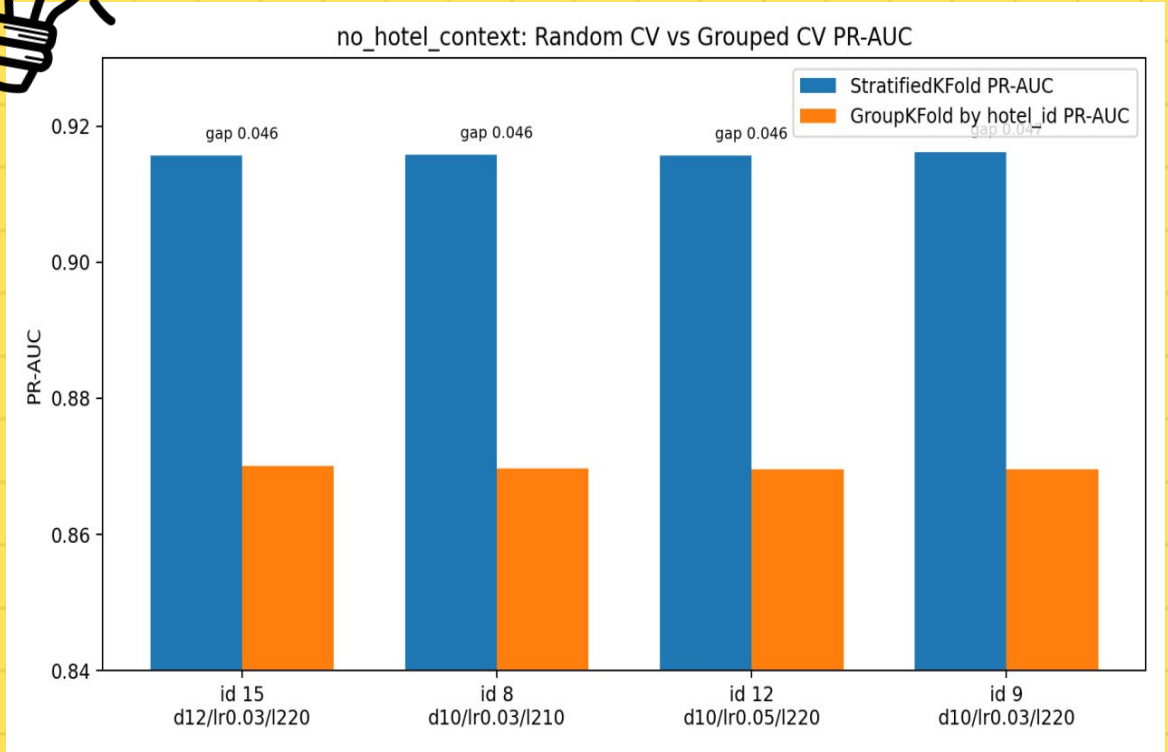

АНАЛИЗ КАЧЕСТВА МАТЧИНГА В РАЗРЕЗЕ ОТЕЛЕЙ

График демонстрирует значительную неоднородность качества предсказаний: модель работает практически идеально для большинства отелей, но сталкивается с глубокими просадками recall на проблемных объектах.

Такая разница в метриках показывает, что сложность задачи зависит не от объема данных, а от специфики паттернов описания внутри каждого отеля.

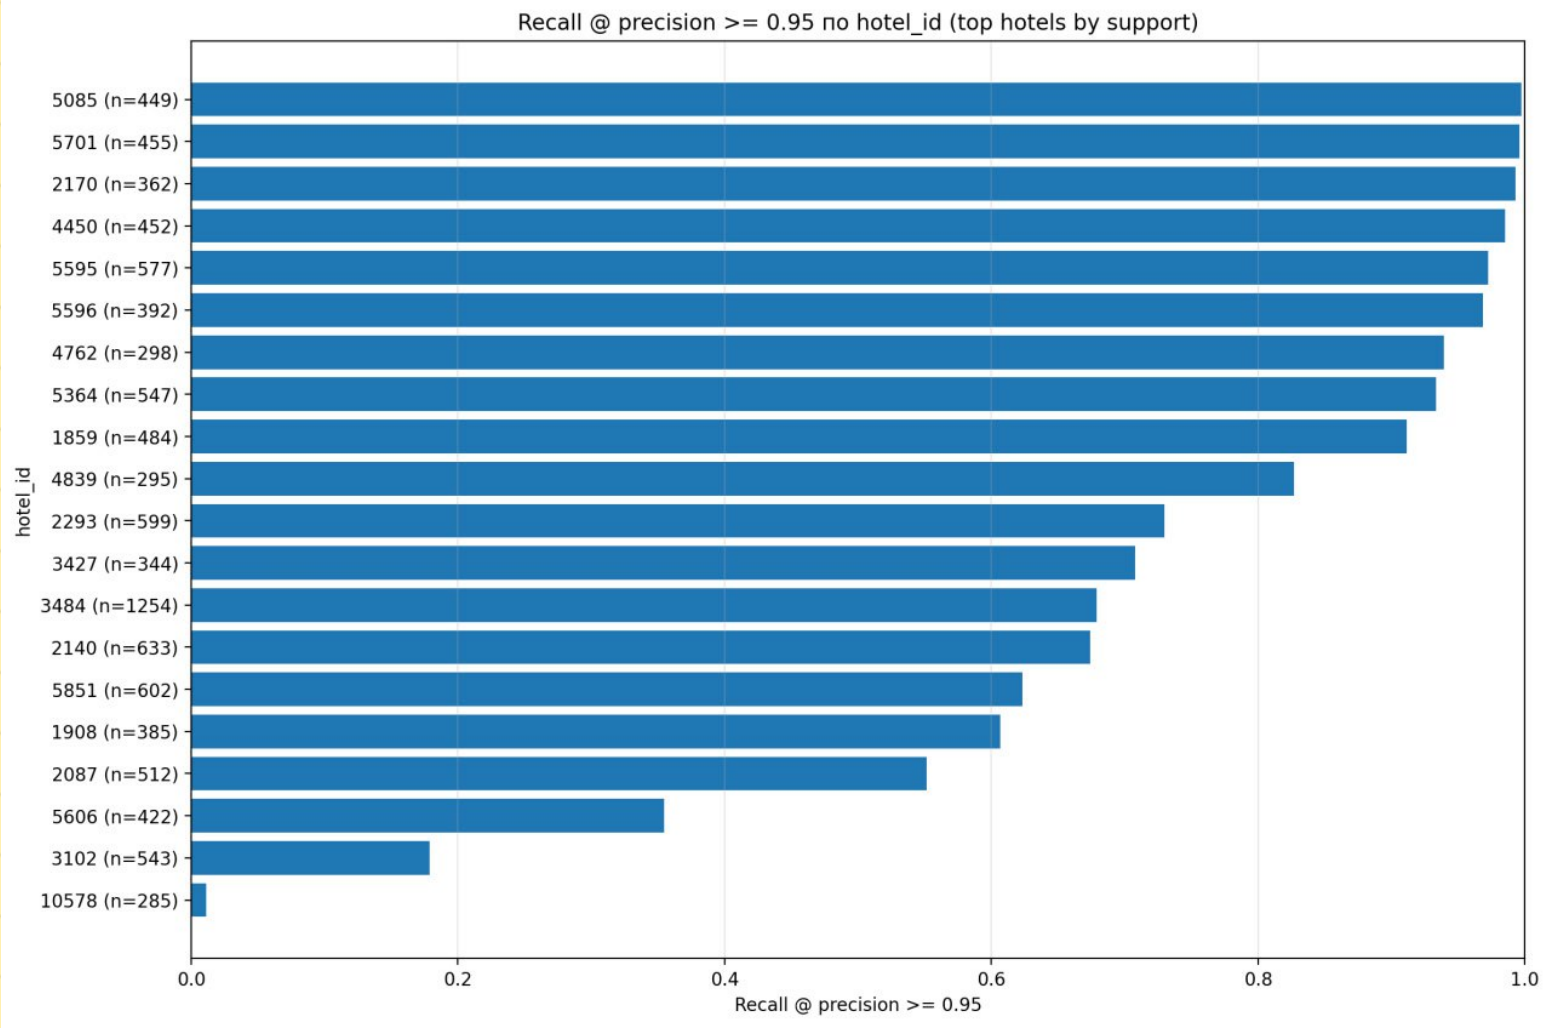

АНАЛИЗ КАЧЕСТВА МАТЧИНГА В РАЗРЕЗЕ HOTEL_ID

В среднем модель показывает высокое качество, но по hotel_id есть заметная неоднородность. Это видно по распределению recall при фиксированном precision 0.95: большая часть отелей лежит в высокой зоне, но есть хвост проблемных hotel_id, где модель находит существенно меньшую долю истинных совпадений.

Наличие отелей с околонулевым Recall на Precision 0.95 сигнализирует о зоне повышенного финансового риска. Для таких объектов автоматика бессильна из-за катастрофической нехватки данных.

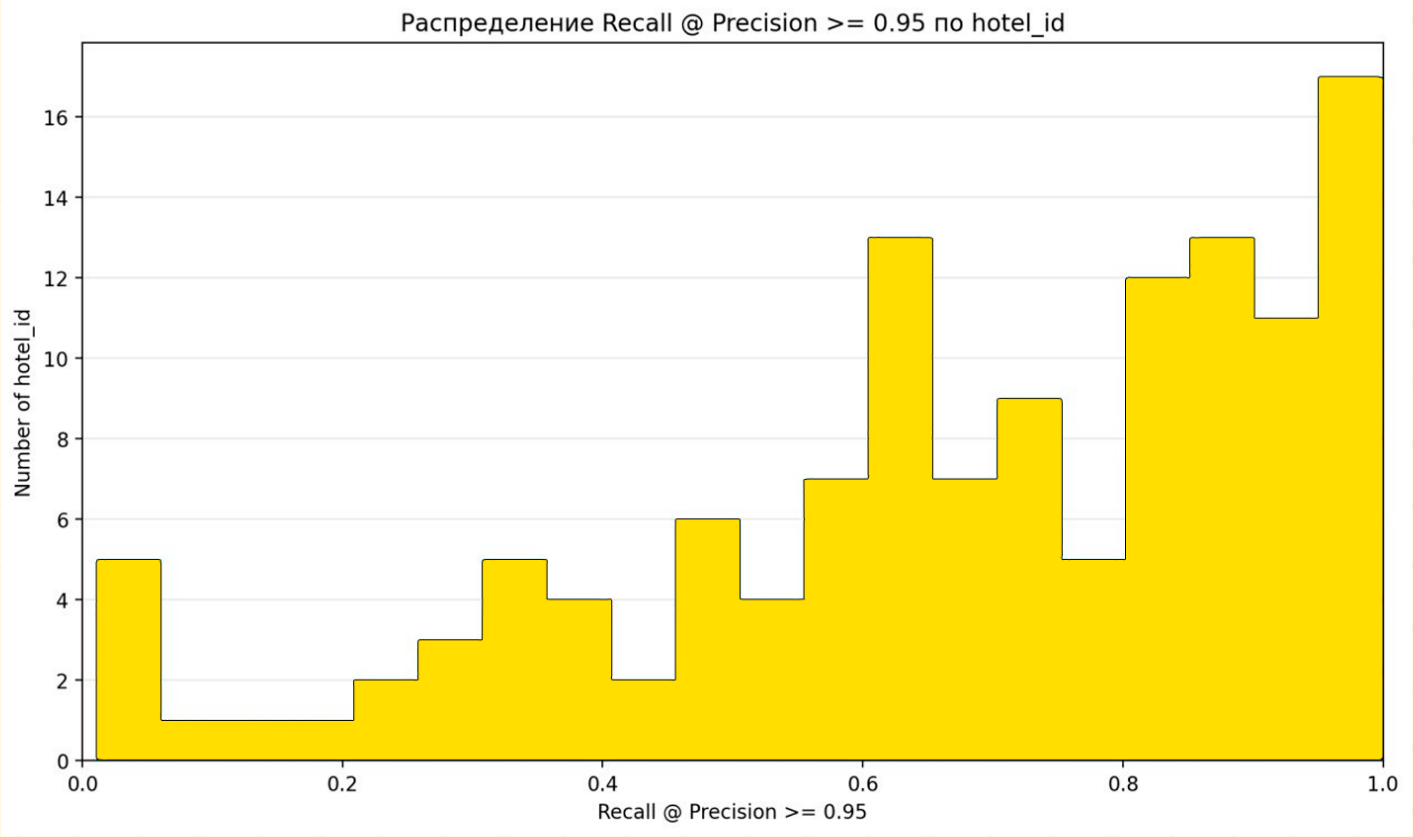

TF-IDF

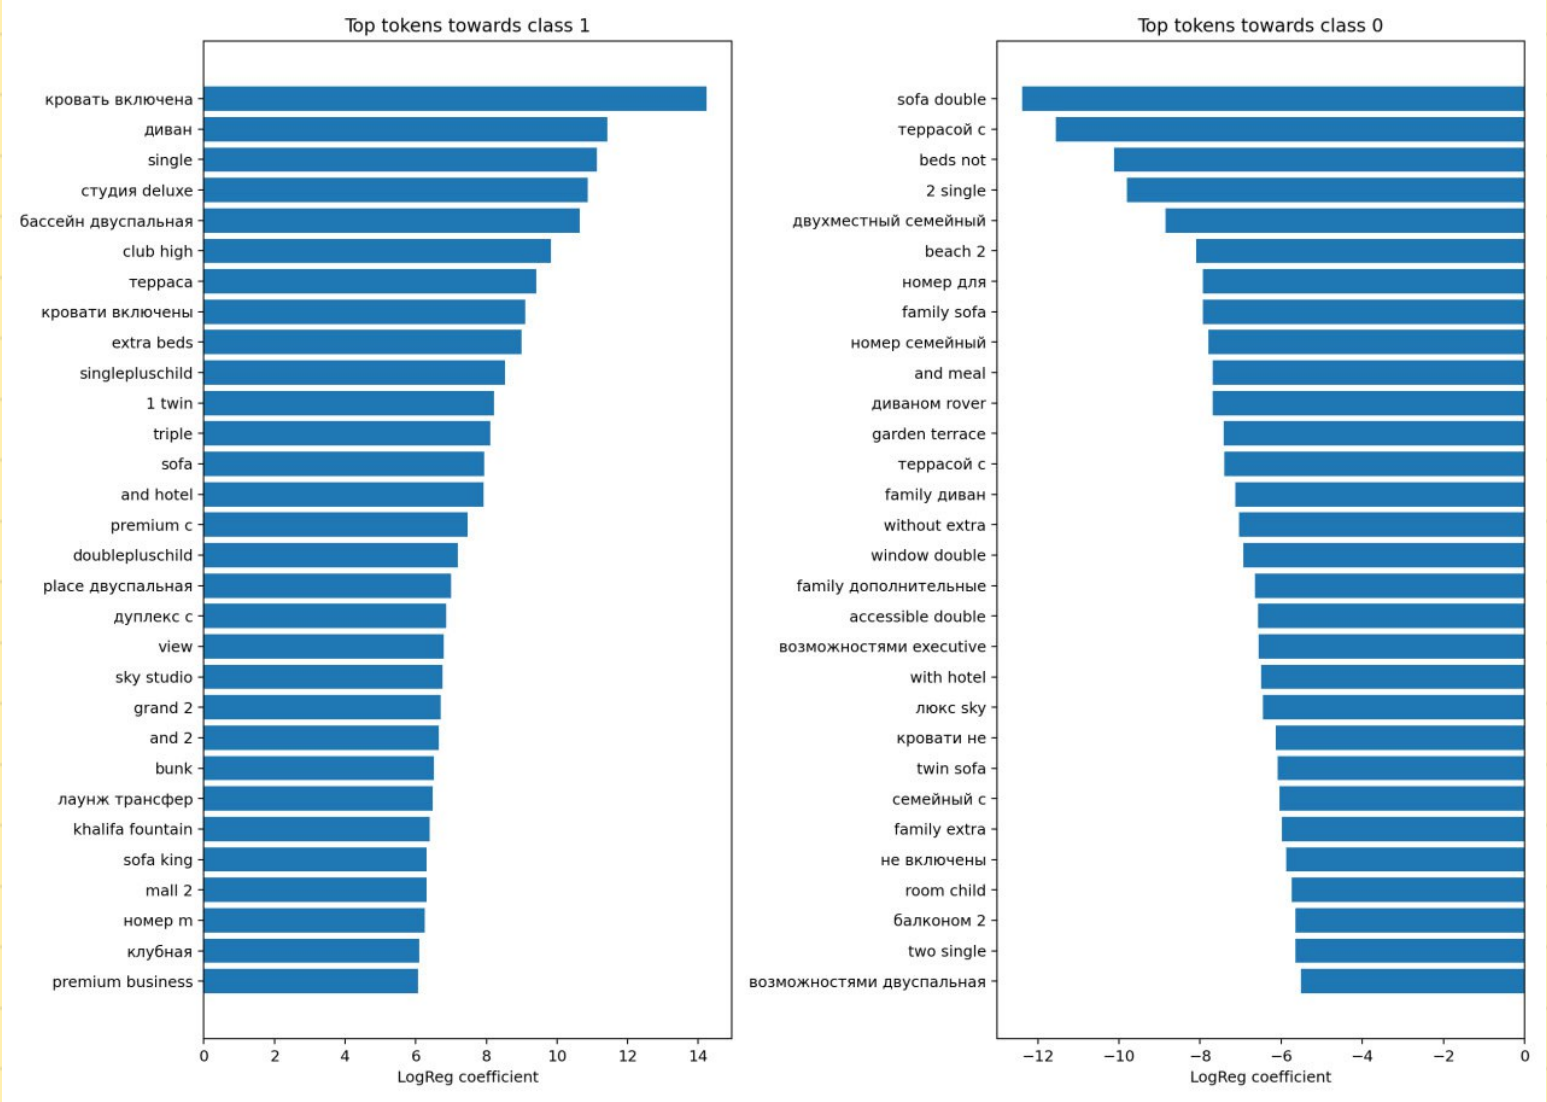

Для интерпретации финальной hybrid-модели мы использовали два уровня анализа.

01 Сам CatBoost анализировался через feature importance, что позволило понять, какие engineered и transformer-признаки сильнее всего влияют на решение.

02 Чтобы интерпретировать именно текстовый сигнал, мы дополнительно обучили интерпретируемую модель TF-IDF + LogisticRegression.

Она показала, какие слова и фразы в названиях комнат чаще ассоциируются с проблемными и непроблемными случаями.

На random 20% holdout модель даёт PR-AUC ~0.906 и Recall ~0.420 при Precision ≥ 95%. На split по hotel_id заметно хуже, что подтверждает сильную внутреотельную специфику задачи.

БИЗНЕС-ЭФФЕКТ

01 **Высокая интерпретируемость.**

02 **Легкость внедрения:**

03 **Минимальные вычислительные затраты**

СПАСИБО ЗА ВНИМАНИЕ!
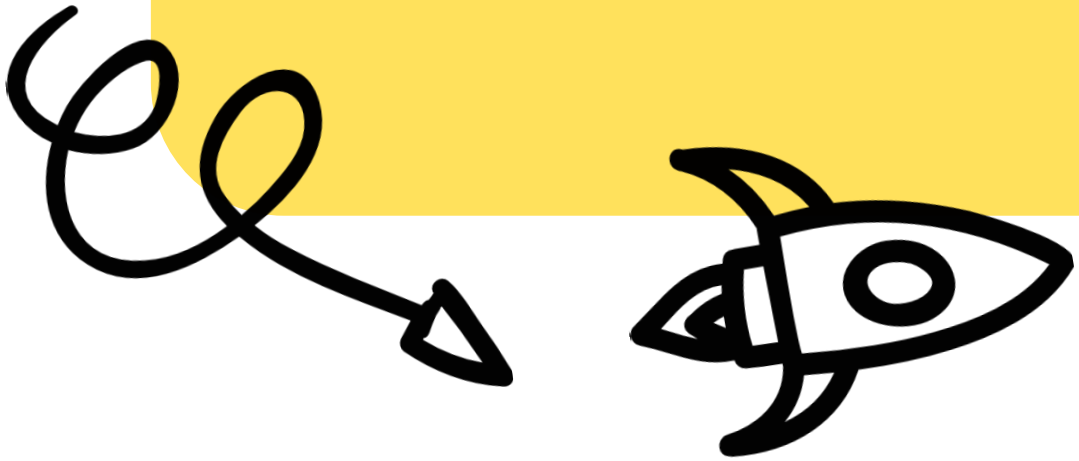
Ссылка на репозиторий: https://sourcecraft.dev/xedex123/mango-united-tbank